

ROTEIRO DE AULA PRÁTICA

Engenharia de Requisitos para ML com GR4ML

Caderno de Exercícios do Grupo
Preencha os templates de cada fase durante a aula

Centro de Informática — CIn/UFPE
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

Grupo (nome dos integrantes)	Projeto da disciplina
<i>Hugo Gusmão</i>	Monitoramento de Operação de Caminhões em Mina
<i>Raissa Tavares</i>	Monitoramento de Operação de Caminhões em Mina
<i>Eraldo Florencio</i>	Monitoramento de Operação de Caminhões em Mina
<i>Josivan Reis</i>	Monitoramento de Operação de Caminhões em Mina
<i>João Alexandre</i>	Monitoramento de Operação de Caminhões em Mina

Links oficiais: https://www.cs.toronto.edu/~soroosh/gr4ml_language.html
https://www.cs.toronto.edu/~soroosh/gr4ml_toy.html

Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/ passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

Objetivo da atividade

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

Cronograma sugerido

Fase	Duração	Conteúdo
Fase 0 — Alinhamento	20 min	Escopo do projeto, stakeholder principal e dor de negócio
Fase 1 — Business View	45 min	Atores, objetivos, indicadores, decisões e perguntas de negócio
Fase 2 — Analytics Design View	45 min	Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas
Fase 3 — Data Preparation View	45 min	Fontes de dados, transformações e pipeline até o dataset final
Fase 4 — Dos modelos aos requisitos	30 min	Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados

As três visões do GR4ML, em uma tabela

Visão	Pergunta que responde	Quem pensaria assim, na vida real	O que sai dela
1. Business View	Quem precisa de quê, e por quê?	Gestor / dono do produto	Diagrama Ator → Goal → Decision Goal → Question Goals
2. Analytics Design View	Que modelo resolve isso, com qual qualidade?	Cientista de dados	Tarefas de ML, algoritmos e métricas ligadas aos softgoals
3. Data Preparation View	De onde vêm os dados e como chegam prontos?	Engenheiro de dados	Pipeline de dados brutos até features prontas



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTE PASSO: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

O Coordenador de Operações de Mina e o Gerente de Segurança Patrimonial buscam

automatizar a contagem de caminhões carregados pelas escavadeiras por turno e a verificação

do estado da caçamba (vazio/cheio) nos checkpoints da portaria. Atualmente, o controle

manual gera erros de medição de produtividade da lavra e vulnerabilidade a fraudes ou desvios

de minério no transporte. A solução utilizará visão computacional para garantir controle

operacional preciso e zerar saídas não autorizadas.

1 FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?

Exemplos de Atores

- *Streaming* → *Gerente de Retenção de Clientes*
- *Fraude* → *Gerente de Prevenção a Fraudes*
- *Saúde* → *Médico Oncologista*
- *Hospital (fluxo de atendimento)* → *Coordenador de Enfermagem*

 **ENTREGÁVEL DESTE PASSO:** Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).

Nome do Ator	Papel na organização
Supervisor de Operações da Mina	Responsável por acompanhar as metas de produção por turno e a eficiência dos equipamentos de escavação.
Auditor / Agente de Portaria	Responsável pela liberação de veículos e prevenção de perdas/fraudes no checkpoint de entrada/saída.

PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

Exemplo (streaming)

- *Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"*
- *Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%*
- *Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."*

 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

Ator	Goal (objetivo)	Indicador (métrica)	Expectativas de qualidade (informal)
Supervisor de Operações	Aumentar a precisão da medição de produtividade da escavação por turno.	Taxa de acurácia na contagem de caminhões por turno (%) · Atual: ~85% (manual) · Meta: > 98%	"Preciso do relatório de contagem do turno consolidado em tempo real no final de cada jornada, sem depender de anotação em papel do operador."
Auditor de Portaria	Eliminar fraudes e desvios de carga na entrada/saída da mina.	Divergência de status de carga na portaria (Nº de incidentes não detectados) · Meta: 0.	"A verificação precisa soar um alarme em menos de 2 segundos na tela da guarita para travar a cancela se um caminhão tentar sair cheio sem autorização."

PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.

Exemplos

- *Streaming*: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- *Fraude*: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- *Hospital*: "Decidir qual paciente deve ser atendido primeiro na triagem"

Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?

 **ENTREGÁVEL DESTE PASSO:** Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.

Supervisor de Operações precisa decidir se ajusta a alocação de caminhões na fila da escavadeira ou encerra a meta produtiva, ao final de cada turno de trabalho.

Auditor de Portaria precisa decidir se aprova a liberação da cancela ou inspeciona manualmente a caçamba do caminhão, a cada passagem no checkpoint.

PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.

Exemplos

- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal
- *Fraude*: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- *Hospital*: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real

 **ENTREGÁVEL DESTES PASSOS:** Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.

Question Goal (a pergunta)	Tipo	Tempo (passado/presente/futuro)	Frequência
Q1 - Quantos caminhões foram carregados pela escavadeira X durante o turno atual?	Quanto	Passado / Presente	Por turno
Q2 - O caminhão no checkpoint está entrando vazio ou saindo cheio conforme o manifesto?	O quê / Qual	Presente	Tempo real (a cada veículo)

Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.

(espaço para desenhar o diagrama da Business View)
Desenho feito - preciso trazer para cá

CHECKPOINT

Antes de seguir para a Fase 2, mostrem esse diagrama ao professor. Nenhum grupo deve avançar sem ter clareza total sobre o problema de negócio.

2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

Tipo	O que faz	Exemplo
Q1 (Contagem na Lavra)	Preditiva / Quantitativa	Identifica eventos de carregamento via análise de vídeo e acumula a contagem automatizada por equipamento.
Q2 (Status Cheio/Vazio na Portaria)	Preditiva	Classifica o estado visual da caçamba (cheio vs. vazio) e cruza com a direção do tráfego (entrada/saída).

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

Question Goal	Tipo de análise	Justificativa
Aumentar a produção ou comprar equipamentos?	Descritiva	Se a produção atingir o objetivo mensal/Anual, não se justifica a aquisição de novos equipamentos
<i>Precisa decidir entre atender a demanda de aumento de produção ou manter as horas de manutenção atuais já programadas para os equipamentos em detrimento da produção</i>	Descritiva	Os equipamentos precisam ter horas de parada para manutenção em função das horas que levam operando no turno para que estejam sempre em condições seguras de operação.
precisa decidir entre melhorar o treinamento ou contratar funcionários experientes	Descritiva	Se os operários mais inexperientes (mão obra mais econômica) conseguem ter a mesma performance dos operários seniors (mão de obra mais cara) então não justifica optar por mão de obra mais cara.

PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

Exemplo (streaming — "prever cancelamento")

- Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)

- *Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural*

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
M1: Contar ciclos de carregamento na lavra	Detecção e Rastreamento de Objetos (Object Detection & Tracking)	1. YOLOv8 + ByteTRACK 2. Faster R-CNN + DeepSORT 3. SSD (Single Shot Detector)
<i>Preencha aqui</i> M2: Classificar caçamba (cheia/vazia) no checkpointi...	Classificação de Imagem / Detecção de Carga	1. ResNet-50 2. EfficientNet-B0 3. YOLOv8 (Classificação Binária)
<i>Preencha aqui...</i>		

PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

Exemplos, com a origem no negócio

- "Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão
- "Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade
- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

Softgoal	Origem (frase do stakeholder ou 'técnico')
Baixa Latência de Inferência	Stakeholder: "A verificação precisa soar um alarme em menos de 2 segundos na tela da guarita"
Baixo Falso Negativo (Alto Recall)	Stakeholder: "Não deixar passar nenhuma saída cheia não autorizada".

Softgoal	Origem (frase do stakeholder ou 'técnico')
<i>Robustez a Intempéries e Poeira</i>	Técnico: O ambiente de mineração possui poeira suspensão contínua e opera sob chuva/noite.
<i>Explicabilidade Visual</i>	Stakeholder / Operação: O auditor precisa ver na tela o frame recortado que gerou o alerta.

PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

✨ O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

💡 Exemplos de vínculo Softgoal → Métrica

- *Fraude*: "Evitar perturbar clientes inocentes" → alta Precisão / baixa taxa de Falso Positivo
- *Saúde*: "Explicabilidade" → uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis
- *Streaming*: "Compatível com o prazo semanal" → tempo de inferência em lote < 2h para toda a base

📌 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

Algoritmo	Softgoal 1 (métrica)	Softgoal 2 (métrica)	Softgoal 3 (métrica)
	Latência (Tempo/frame)	Recall (Baixo Falso Negativo)	Robustez Poeira/Noite (mAP@50)
YOLOv8 + ByteTRACK	< 20 ms	96%	91%
Faster R-CNN + DeepSORT	~120 ms	98%	93%
EfficientNet-B0	~15 ms	92%	85%

Conclusão do grupo — qual algoritmo escolheriam e por quê:

Escolhemos o pipeline YOLOv8 + ByteTRACK. Ele garante processamento em borda (Edge Computing)

em menos de 20 ms por frame (atendendo ao requisito de 2 segundos na portaria), apresenta altíssimo Recall

(96%) para não permitir evasão de carga e possui arquitetura robusta contra perturbações visuais (poeira e baixa iluminação)

PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.

 Exemplo (streaming)

- "Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."

 **ENTREGÁVEL DESTE PASSO:** Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.

Garantindo um *Recall* de 96% e tempo de inferência inferior a 20 ms, o sistema detectará imediatamente

divergências de carga no checkpoint sem criar filas na portaria A automação da contagem na lavra eliminará

erros humanos de anotação, elevando a acurácia do indicador de produção de turno de ~85% para mais de 98% .

 CHECKPOINT

Antes de seguir para a Fase 3, garantam que cada Softgoal tem uma métrica associada — não deixem nenhum 'bonito no papel'.

3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o quê assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

Fonte de dados (tabela)	Principais campos/atributos
Feed Câmeras Lavra (RTSP)	camera_id, timestamp, video_frame, equipment_id
Feed Câmeras Checkpoint (RTSP)	camera_id, timestamp, video_frame, gate_id
Cadastro/Leitura LPR (Placas)	truck_plate_id, driver_id, timestamp_entry, timestamp_exit
Log de Balança / ERP	ticket_id, truck_plate_id, weight_gross, status_declared

PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

Nº	Transformação aplicada	Tabela(s) de origem
1	Amostragem e Redimensionamento: Captura de frames RTSP e resizing para 640 x 640 pixels.	Feed Câmeras Lavra e Checkpoint

Nº	Transformação aplicada	Tabela(s) de origem
2	Filtragem CLAHE: Aplicação de contraste adaptativo para mitigar poeira e iluminação noturna.	Feed Câmeras Checkpoint
3.	Recorte de ROI (Region of Interest): Isolamento visual da área da caçamba e da placa.	Video Frames
4.	Tracking & Agregação Temporal: Contagem incremental ao rastrear a pá sobre a caçamba.	Feed Câmeras Lavra

PASSO 3.3 Dataset final e Pipeline

Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.



Exemplo de dataset preparado (streaming)

• Colunas: *Cliente_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*



ENTREGÁVEL DESTE PASSO: Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

Coluna (feature)	Descrição	De qual fonte / transformação vem
truck_id	Identificador único / placa do caminhão	Leitura LPR / Câmera Checkpoint
state_detected	Estado predito (0: Vazio, 1: Cheio)	Inferência do modelo YOLOv8
confidence_score	Confiança da predição (0.0 a 1.0)	Saída da camada Softmax do modelo
load_cycles	Nº de caçambadas despejadas no turno	Acúmulo de eventos da Câmera Lavra
gate_direction	Direção do movimento (Entrada / Saída)	Tracking / Sensores da portaria

(espaço para desenhar o pipeline: Fontes → Transformações → Dataset Final → Algoritmo)



CHECKPOINT

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

Ferramentas recomendadas

Como o GR4ML estende conceitos do i* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
 - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
 - Nuvens → Softgoals
 - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

Verificação final

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

Preenchem a frase com o projeto de vocês

Para ajudar o Supervisor de Operações e o Auditor de Portaria a decidir se liberam o veículo na portaria e se

fecham a meta do turno, respondendo à pergunta quantos caminhões foram carregados e se o caminhão está cheio

ou vazio na portaria, vamos usar YOLOv8 + ByteTRACK, que satisfaz os softgoals baixa latência, baixo falso

negativo e explicabilidade medidos por tempo de inferência (<20ms) e Recall (>95%), usando os dados do dataset

recortado de frames com estados da caçamba vindos de câmeras IP da lavra e portaria integradas ao LPR. Isso

deve impactar o indicador Acurácia de Turno e Divergência na Portaria em elevação para >98% de precisão e redução a zero dos desvios.



FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.



Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitação só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

Mapa de tradução: do elemento do GR4ML ao tipo de requisito

Elemento já modelado	Tipo de requisito gerado	Pergunta-guia para redigir
Decision Goal + Question Goal + Insight (Fase 1)	Requisito Funcional (RF)	O que exatamente o sistema precisa calcular ou entregar?
Softgoal + Métrica associada (Passo 2.3–2.4)	Requisito Não-Funcional (RNF)	Que qualidade o sistema deve garantir, e como ela será medida?
Entidades + Dataset Preparado + Transformações (Fase 3)	Requisito de Dados (RD)	Que dados precisam ser coletados, integrados e tratados, e de onde vêm?
Indicador (Passo 1.2)	Critério de Aceitação do conjunto de requisitos	Como saberemos, no negócio, que os requisitos implementados geraram valor real?

PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).



Modelo de frase (template)

- "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."



Exemplo preenchido (streaming)

- "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."



ENTREGÁVEL DESTE PASSO: Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-01	O sistema deve computar incrementalmente os ciclos de carregamento por escavadeira a partir do fluxo de vídeo da lavra, exibindo o total de caminhões carregados por turno para o Supervisor de Operações.	Question Goal Q1 / Decision Goal Supervisor

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-02	<i>O sistema deve classificar a caçamba dos caminhões em 'cheia' ou 'vazia' na aproximação da portaria e emitir um alerta sonoro/visual caso um caminhão saia cheio sem registro de carga.</i>	Question Goal Q2 / Decision Goal Auditor
	<i>Preencha aqui...</i>	

PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.

Modelo de frase (template)

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."

Exemplos preenchidos

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)

 **ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

ID	Requisito Não-Funcional (RNF)	Origem no modelo (Softgoal/Métrica)
RNF-01	<i>O sistema deve realizar a inferência de status da caçamba e enviar o sinal de liberação/alerta em tempo de resposta inferior a 1,5 segundo.</i>	Softgoal: Baixa Latência / Métrica: Inferência < 20ms
RNF-02	<i>O sistema deve realizar a inferência de status da caçamba e enviar o sinal de liberação/alerta em tempo de resposta inferior a 1,5 segundo.</i>	Softgoal: Baixo Falso Negativo e Robustez a Poeira
	<i>Preencha aqui...</i>	

PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.

Modelo de frase (template)

- "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."

Exemplo preenchido (streaming)

- "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."

 **ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD-01	O sistema deve ingerir feeds contínuos de vídeo RTSP (mínimo 1080p a 15 FPS) instalados nos pontos de carregamento e no checkpoint.	Alimenta RF-01 e RF-02
RD-02	O sistema deve integrar-se ao banco de dados LPR para associar a imagem do estado da caçamba à placa do caminhão identificada.	Alimenta RF-02
	<i>Preencha aqui...</i>	

PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

Modelo de frase (template)

- "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

Exemplo preenchido (streaming)

- "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTE PASSO:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

Este conjunto de requisitos será considerado bem-sucedido se a taxa de divergência/fraude de carga na portaria for reduzida a zero e a precisão da contagem de carregamentos por turno atingir no mínimo 98% nos primeiros 90 dias de operação.

Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.



Estrutura do documento a ser entregue

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

Reflexão crítica do grupo

O ML era realmente necessário aqui?

Sim. A auditoria visual contínua por operadores humanos é altamente falha devido à fadiga operacional, poeira constante e turnos de 24 horas. Além disso, métodos tradicionais sem IA (como simples sensores de presença ou balanças soltas) não conseguem discernir visualmente se o volume da caçamba contém minério ou resíduo. O uso de redes de Visão Computacional traz precisão objetiva e automatizada.

O que a formalização revelou?

A formalização dos Softgoals evidenciou que a Acurácia geral isolada não salvaria o projeto. Se o sistema operasse com alta acurácia mas tivesse alta latência, a fila de caminhões na portaria pararia a mineração.

Descobrimos que a latência de inferência e o Recall (evitar falsos negativos na portaria) eram restrições de negócio muito mais críticas do que a pura acurácia do modelo.
